





▼ Introducció a la Bioinformàtica

Toni Monleón - 2026



🌐 INTRODUCCIÓ A LA BIOINFORMÀTICA (8h)

- Introducció (dia 1)
- **Bases de dades (dia 1)**
- Alineament de seqüències (dia1 / dia2)
- Cerques per Similitud (dia 2 / dia 2)
- Next Generation Sequencing (NGS) (dia 3 / dia 4)
- Gene Expression Omnibus database (GEO) (dia 4)

BASES DE DADES

Bioinformatics Databases, Software, and Tools



Molecular Evolutionary
Genetics Analysis



Basat en els apunts de l' assignatura Biologia II curs 2022-2023. (Modificació de Toni Monleón-Getino. Departament de Genètica, Microbiologia i Estadística. Grup de recerca BIOST3 i GRBIO)
Universitat de Barcelona
Duració:8h

SOLS PER US DOCENT

🌐 Qué és una base de dades?


- Una base de dades és simplement una manera organitzada d'emmagatzemar i gestionar informació.
- N'hi ha de molts tipus, però el seu objectiu principal és fer eficient l'accés i el tractament de la informació.
- L'explosió de disponibilitat de dades de biologia molecular des de finals del segle passat i fins a l'actualitat ha convertit a les bases de dades biològiques en una peça essencial en qualsevol camp de les ciències de la vida, i en punt de partida gairebé obligat en Bioinformàtica.

What is a Database/Resource?

- **Collection of data in the related format**
 - structured
 - searchable (index)-> table of contents
 - updated periodically (release) -> new edition
 - cross-referenced ([hyperlinks](#)) -> links with other db
- Includes also associated tools (software) necessary for db access, db updating, db information insertion, db information deletion....

🌐 Informació a les bases de dades


- El problema de com organitzar la informació per tal d'assolir aquesta eficiència en l'accés i el tractament de la informació no és en absolut trivial.
- Cal una estructura que permeti no solament contenir la informació sinó modificar-la, consultar-la amb criteris adients (que poden arribar a ser molt complexes per tal d'arribar exactament a la informació que volem entre una gran quantitat de dades),fer-la disponible a potencialment molts usuaris i per diferents canals, etc.
- Això implica no solament una estructura de dades adient sinó també sistemes de software i hardware associats (no entrarem en detall en això).



Empieza a programar o a [crear código](#) con IA.

EXEMPLE: LA BASE DE DADES PDB

- Penseu, per exemple, en com organitzar la informació de l'estructura terciària (3D) d'una proteïna a partir de l'estructura primària (seqüència). Això és el que fa el Protein Data Bank (PDB): <https://www.rcsb.org/>



ESTRUCTURES 3D IMPLICADES A RESISTÈNCIA A ANTIBIOTICS

- El PDB (<https://www.rcsb.org/>) és la base de dades més utilitzada a nivell de Biologia estructural.

- El PDB conté estructures 3D de proteïnes. L'exemple de la diapo és part de les dades emmagatzemades per l'estructura d'una Actina.
- Per organitzar la informació de l'estructura 3D d'una proteïna, necessitem emmagatzemar i organitzar les dades de cada un dels àtoms que componen tots els seus aminoàcids. En concret necessitem les 3 coordenades a l'espai de cada un dels àtoms respecte dels altres. A més, necessitem altres dades com l'ordre en la cadena d'àtoms i aminoàcids, a quin aminoàcid correspon

cada àtom, i altres qüestions rellevants en el camp d'estructura de proteïnes. Aquesta informació es desa a un arxiu pdb i se li otorga un codi alfanumèric de 4 lletres o números (PDB ID), per exemple el codi 1J6Z està assignat a la Actina (link a <https://www.rcsb.org/structure/1J6Z>).

- I tot això s'ha d'emmagatzemar per molts milers de proteïnes, i de manera eficient pel que fa a poder actualitzar dades massivament si és necessari, (i solament les que calgui), i també pel que fa a que milers d'usuaris accedeixin a les dades en cada moment, etc.
- Per tant, no és una qüestió trivial en absolut.
- Veure format dels camps registrats de PDB a: https://proteopedia.org/wiki/index.php/Atomic_coordinate_file


Atomic Coordinates: PDB Format


		Amino Acid		Chain name		Sequence Number		-----Coordinates-----			
		Element						X	Y	Z	(etc.)
ATOM	1	N	ASP	L	1			4.060	7.307	5.186	...
ATOM	2	CA	ASP	L	1			4.042	7.776	6.553	...
ATOM	3	C	ASP	L	1			2.668	8.426	6.644	...
ATOM	4	O	ASP	L	1			1.987	8.438	5.606	...
ATOM	5	CB	ASP	L	1			5.090	8.827	6.797	...
ATOM	6	CG	ASP	L	1			6.338	8.761	5.929	...
ATOM	7	OD1	ASP	L	1			6.576	9.758	5.241	...
ATOM	8	OD2	ASP	L	1			7.065	7.759	5.948	...

Element position within amino acid

ENTREU EN UN REGISTRE DE LA BASE DE DADES PDB

- Per exemple entreu a PDB el codi 1J6Z, que està assignat a la Actina (link a <https://www.rcsb.org/structure/1J6Z>) i doneu un cop d'ull
- Amb aquesta informació el PDB permet la visualització 3D de la estructura de les proteïnes, en aquest cas de la Actina. També inclou molta més informació com pot ser la tècnica amb que s'ha determinat la estructura, la resolució de la posició dels àtoms, la fiabilitat de les dades, etc.
- Podreu trobar més informació en els icones representats amb un "?" o una "i".* La opció "3D View" (<https://www.rcsb.org/structure/1J6Z>) et permeten fer una visualització 3D de la estructura o buscar estructures similars.






Bases de dades: el model relacional

- Una base de dades és una col·lecció organitzada d'informació estructurada, o dades, normalment emmagatzemades electrònicament en un sistema informàtic.
- Un model molt habitual d'organitzar la informació en aquestes bases de dades és el model relacional o base de dades relacional.


Bioinformatics

- Les dades es poden imaginar representades mitjançant taules físiques (semblants a les d'un full de càlcul).



- Cada taula pot tenir enllaços a altres taules, que permeten extreure informació relacionada, de forma similar als enllaços que trobem entre diferents pàgines web.

Exemple de taules d'una base de dades genòmica:




EXPLICACIONS ADICIONALS

- En les bases de dades relacionals (les més clàssiques i utilitzades), les dades es disposen en estructures conceptualment similars a taules. La informació es divideix en diferents taules, cada una contenint informació referida a una 'entitat' rellevant dins la nostra base de dades, i cada taula està connectada a altres per tal de poder combinar les diferents informacions coherentment.
- Per exemple, en el nostre cas podríem tenir una base de dades amb una taula per informació dels gens, una altra per informació de transcrit i una altra per informació d'exons.
- Per què no tenir tota aquesta informació en uns sola taula? Si volguéssim incloure tota la informació de les 3 taules esmentades en una sola, passaria que:
 - Cada filera amb informació de cada transcrit hauria de tenir repetida la informació del gen al que correspon.
 - Cada filera amb informació de cada exó hauria de tenir repetida la informació del gen al que pertany i també dels transcrits en els que es troba.
- Això faria que hi hagués molta redundància d'informació (ús emmagatzematge innecessari, més lentitud d'accés), i que l'actualització i manteniment de la informació fos més difícil (canvis de la mateixa informació s'han de fer en molts llocs, més propens a errors).
- Enlloc d'això, tenim diferents taules, cadascuna amb informació d'una entitat concreta (en el nostre cas, gens, transcrits, i exons), que tenen enllaços entre elles mitjançant identificadors únics per a cada element de cada taula (cada gen, transcrit i exó en tindrà un identificador únic). Així, per exemple a la taula d'exons, podem saber a quin gen i a quins transcrits del gen es troba cada exó perquè podem seguir els seus identificadors que ens enllaçaran a les taules que contenen les seves dades.


Taules, registres i camps

A single piece of information in a database is called:

A) File
B) Field
C) Record
~~D) Data set~~



- Qualsevol taula d'una base de dades relacional consta d'una sèrie de files o registres (records, entries or tuples) que representen la informació de cada entitat o individu.



- Les columnes de la taula és el que s'anomenen els camps (fields or attributes) i representen tots els atributs per a cada individu (o registre).
- Per exemple, en una taula que contingui informacions d'exons, cada registre (filera) contindrà informació d'un exó en particular, i cada camp (columna) seria una categoria d'informació sobre aquest exó que emmagatzemem. Per exemple, serien camps: a quin gen pertany l'exó, a on comença, a on acaba, la seva classe exònica, etc. A cada un d'aquest camps els hi donariem un nom concret (els encapçalaments de cada columna, vist com si fos una taula d'Excel).
-

EXEMPLE D' ENTRADA A LA BASE DE DADES ENA (EUROPEAN NUCLEOTIDE ARCHIVE)

Quan volem obtenir informació d'una de les bases de dades biològiques lliurement disponibles, com per exemple a ENA (European Nucleotide Archive, <https://www.ebi.ac.uk/ena>), el resultat que obtenim no s'assembla a aquesta estructura de taules relacionades que hem descrit. En canvi, el que obtenim és una VISTA (view), que és el format amb el qual la base de dades ens presenta la informació que li hem demanat.

Per exemple proveu amb una histona humana: <https://www.ebi.ac.uk/ena/browser/view/BN000065>

De les taules a la vista

A single piece of information in a database is called:

A) File
B) Field
C) Record
~~D) Data set~~

The diagram illustrates three patient records stacked vertically. Each record contains the following fields:


- Patient Name: SMITH, KEVIN
- DOB: 3/1/46
- Patient Name: SMITH, KEITH
- DOB: 11/30/61
- Patient Name: SMITH, JOHN
- DOB: 8/1/53
- SEX: M
- SSN: 099-86-8215
- MARITAL STATUS: MARRIED
- Address: 555 Dunstable Parkway, San Francisco, CA 98456
- Telephone: 700-555-5432
- SERVICE CONNECTED: YES
- SERVICE ENTRY DATE: 6/1/71

A box labeled "Three patient records!" points to the three stacked records. Another box labeled "Individual fields within a record." points to a specific field within one of the records.

- Nosaltres NO interaccionem directament amb les taules i relacions de les bases de dades relacionals.

*La nostra interacció es limita a enviar una CONSULTA o query (demanar a la base de dades aquelles dades que volem), i obtenir una VISTA que ens presenta les dades que hem demanat formatades d'una determinada manera, prioritzant un objectiu o un altre (pot ser una vista prioritzant la llegibilitat, o prioritzant la densitat d'informació, o fins i tot destinada a processament automàtic i no per ser interpretada per humans, etc.)

Anatomy of a View



EXEMPLE AMB ENA (EUROPEAN NUCLEOTIDE ARCHIVE)

Busquem per exemple lipases de Pseudomonas: <https://www.ebi.ac.uk/ena/browser/text-search?query=%09Pseudomonas%20lipase>

- En aquesta vista de ENA, tenim els camps d'informació per cada registre (record) per exemple el primer registre: https://www.ebi.ac.uk/ena/browser/view/GCA_001653895.1, en format de codi (per exemple el codi DE vol dir Description), i la informació de cada camp d'aquests codis en cada línia, que correspondria al contingut dels registres.

<https://www.ebi.ac.uk/ena/browser/text-search?query=%09Pseudomonas%20lipase>

- Però com veieu, la base de dades ens ofereix una vista diferent a una taula per millorar la llegibilitat en aquest cas (clicar on diu Assembly View all 5 results.).
- Pateu atenció als camps ID (Accession o similar, poden tenir altres noms) de cada registre, recordeu que són únics i que en bona part gràcies a ells es poden relacionar les diferents taules que componen les bases de dades relacionals.

EXEMPLES DE DIFERENTS CAMPS EN BASES DE DADES BIOINFORMÀTIQUES

- The EMBL Nucleotide Sequence Database <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC102461/>

Accession #, Sequence length, Molecule type →

Sequence Origin, Taxonomy →

References →

Features →

Protein Translation →

DNA Sequence Data →

```

LOCUS AY279110 2704 bp DNA linear PRI 09-MAR-2005
DEFINITION Alouatta belzebul beta globin gene, complete cds.
ACCESSION AY279110
VERSION AY279110.1 GI:33415416
KEYWORDS
SOURCE
  ORGANISM Alouatta belzebul (black-and-red howler monkey)
  Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi;
  Mammalia; Eutheria; Euarchontoglires; Primates; Platyrrhini;
  Cebidae; Alouattinae; Alouatta
REFERENCE
  1 (bases 1 to 2704)
  AUTHORS Prychitko,T., Johnson,R.M., Wildman,D.E., Gumucio,D. and Goodman,M.
  TITLE The phylogenetic history of New World monkey beta globin reveals a
  JOURNAL Mol. Phylogenet. Evol. 35 (1), 225-234 (2005)
  PMID 15737593
  REFERENCE
  2 (bases 1 to 2704)
  AUTHORS Prychitko,T.M., Goodman,M. and Johnson,R.M.
  TITLE Direct Submission
  JOURNAL Submitted (18-APR-2003) Anatomy, Wayne State University, 540 East
  Canfield 4340 Scott Hall, Detroit, MI 48201, USA
FEATURES
  Location/Qualifiers
    source
      1..2704
      /organism="Alouatta belzebul"
      /mol_type="genomic DNA"
      /db_xref="taxon:30590"
    join(<952..1043,1174..1396,2228..2356)
    /product="beta globin"
    CDS
      join(952..1043,1174..1396,2228..2356)
      /codon_start=1
      /product="beta globin"
      /protein_id="AAQ18218.1"
      /db_xref="GI:33415417"
      /translation="MRLLTQKAAFTALMKQVDEYGGALGRLLVYTFQDFE
      SPQDLSFGAAMBNPKWAKGKQVLGAFSDGLNLEKQTFAGLSLCTKLHVDPE
      NPLIGNLVLCVLAGHFGKEFTVQVQATQCVVAGVANAIAKQH"
ORIGIN
  1 taatctgagc caagcttggg agacttttc ctttctacc cctactttt aagtcacga
  61 agntctctg ttttccaga aactttttc gatgagtcg ggcagaaca gttnatgtc
  121 ccagynaac ctccacttg acacccctg ttacogtatt gtagtcta ctttgggtg
  181 tgaagtactt ttactattt tgtattttt actgattaa aagatctca gttttcact
  241 ttgtgtttc caaatctaa taagtactg ttacacaga cacactgatt tgtattatt
  301 ctgttttag acatattta ttattacat gagcaatta agaaaactg acaacaaca
  361 aatgaataa tgcattata tatttttta ccagaagtt ttatccaa tcaggagaag
  421 atatacttg aactgagga gaattttat cactctgtc ctgtaattt ttgcatatt
  2281 caacccaca gtgcagctg cctacaga agtgggtgc ggtgtgcta atgocctgc
  2341 tcacaagtc cactaagtc ctttctgc tgctcaatt ctattaaag ttctttgtt
  2401 ccaaaagtc aactattaa cttgggata ttacagagg ctttaagat ctggatttg
  2461 cctataaac aactattat ttoattgaa tgggtgatt aaattattc tgaattttt
  2521 actcaaaag gcatgggga agtcagtcg ttgaacact aagaaagc actagttca
  2581 aactgggga aatcactat atctttaac cctgaaga agtggggt goaaacept
  2641 aatgcacott gacagcagc cctgatgoc atgcattat caacocaaag aaaaggattc
  2701 aagt
  //
  
```

- UNIRPOT: https://www.uniprot.org/help/return_fields

UniProt Submission Page

HELP FAQ DEMO STATS

Community Bibliography Submissions

4 Compose Query

Choose displaying fields 5

UniProt AC contains Submit Search Reset Search Hide/Show Query

Case Sensitive Search

Refresh Prev Next Go to page: 1 of 48 page(s) in total; Now displaying 1 - 50 of 2394 results. [Display 50 rows in a page] Sorting results by Submit Date, in descending order.

Download Selected Clear Selected Download All Search Results 6

UniProt AC	UniProt Status	Protein Name	Organism	PMID	Article Title	Category	Annotation	ORCID	Submission Status
Q99944	Reviewed	Epidermal growth factor-like protein 8	Homo sapiens (Human).	33712610	Schwann cell plasticity regulates neuroblastic tumor cell differentiation via epidermal growth factor-like protein 8.	[Function]	Protein/gene_name: EGFL8. Function: In neuroblastoma, EGFL8 may act as neurite outgrowth factor by activating kinases involved in neurogenesis.	0000-0002-3084-2212	Checked
Q8EF68	Unreviewed	Protein phosphatase with response regulator receiver modulation	Shewanella oneidensis (strain MR-1).	27810894	The General Stress Response Is Regulated by a Partner Switch in the Gram-negative Bacterium	[Function][Interaction][Sequence]	Protein/gene_name: CsrR. Function: Response regulator, serine phosphatase and serine kinase. It phosphorylates and dephosphorylates	0000-0002-0113-3169	Checked

- PDB: <https://www.cgl.ucsf.edu/chimera/docs/UsersGuide/tutorials/pdbintro.html>

Domain Annotation: SCOP/SCOPe Classification


SCOP Database Homepage

Chains	Domain Info	Class	Fold	Superfamily	Family	Domain	Species	Provenance Source (Version)
A	d4hhba_	All alpha proteins	Globin-like	Globin-like	Globins	Hemoglobin, alpha-chain	Human (Homo sapiens) [TaxId: 9606]	SCOPe (2.08)
C	d4hhbc_	All alpha proteins	Globin-like	Globin-like	Globins	Hemoglobin, alpha-chain	Human (Homo sapiens) [TaxId: 9606]	SCOPe (2.08)
B	d4hhbb_	All alpha proteins	Globin-like	Globin-like	Globins	Hemoglobin, beta-chain	Human (Homo sapiens) [TaxId: 9606]	SCOPe (2.08)
D	d4hhbd_	All alpha proteins	Globin-like	Globin-like	Globins	Hemoglobin, beta-chain	Human (Homo sapiens) [TaxId: 9606]	SCOPe (2.08)


Structure based classification

Evolution based classification

- Evidentment, cada base de dades pot tenir diferents camps de dades, tot i que molts són similar i en gran part equivalents si parlem de bases de dades que contenen informació del mateix tipus.



🌐 Consultes a les bases de dades (query), SQL



- Una consulta o "query" representa aplicar un cert filtre als registres de la totalitat
- Aquestes preguntes o filtres es fan mitjançant un programa informàtic anomenat consulta o gestor de la base de dades, el qual accedeix a la base de dades i retorna la informació sol·licitada a l'usuari.
- El llenguatge de programació en el que es fan les peticions que es fan als gestors de les bases de dades s'anomena SQL (structured query language)

EXPLICACIONS ADICIONALS

- Una consulta a una base de dades ha de contenir uns criteris per tal de restringir el resultat a uns certs registres que són dels nostre interès. Això implica que hem de conèixer com codificar aquest criteri de cerca, que també podríem anomenar filtre. Ho veurem una mica més endavant.
- Una vegada la base de dades rep la consulta, un software especialitzat en obtenir eficientment la informació requerida de la base de dades, i que s'anomena gestor o motor de base de dades (o database engine), s'encarrega de buscar i obtenir la informació i de servir-la a una altra part del sistema per construir amb ella una vista, com ja hem dit.
- Hi ha llenguatges específics per comunicar consultes als motors de bases de dades, com SQL, però vosaltres no interaccionareu directament ni amb aquest llenguatge ni amb el motor de base de dades, ja que les bases de dades online us faciliten interfícies d'ús més senzilles per fer consultes i obtenir vistes.
- El vostre cas seria similar a l'analogia del bibliotecari: vosaltres aneu a una biblioteca (base de dades) i demaneu un llibre (consulta) al bibliotecari (motor de base de dades). Vosaltres no sabeu com s'ha de buscar el llibre a la biblioteca, l'únic que feu es demanar-ho al bibliotecari. El bibliotecari (que sí sap com s'organitza la biblioteca i on trobar els llibres), va a buscar el llibre i us l'entrega.
- Heu obtingut el llibre solament amb una consulta, sabent molt poc de com funciona la biblioteca!

🌐 Proveïdors, bases de dades i eines informàtiques (query), SQL

Bioinformatics Databases, Software, and Tools



Podem parlar de 3 aspectes en relació a proveïdors de recursos, bases de dades i eines bioinformàtiques:

- Els proveïdors de recursos: Son organitzacions especialitzades en tenir i mantenir les bases de dades i les eines per accedir-hi en un marc integrat (habitualment son centres supra-estats)
- Les bases de dades (DBs): contenen informació especialitzada, habitualment estructurada en forma relacional
- Les eines informàtiques (programari): Serveixen per cercar informació dins les bases de dades, manipular-les, actualitzar-les, generar noves dades, etc

Informació adicional

Aquí ens referim a recursos i bases de dades disponibles online, i que podeu utilitzar tant via online com descarregar-los i utilitzar en els vostres ordinadors o computadors més potents. En el vostre cas per aquesta pràctica utilitzarem recursos disponibles via online, molt més senzills de fer servir (encara que també és molt fàcilment d'utilitzar un programari específic mitjançant un llenguatge de programació com R).

🌐 Centres i recursos importants

Bioinformatics Databases, Software, and Tools



- **Proveïdors de recursos importants a nivell mundial:**

- European Molecular Biology Laboratory (EMBL: <https://www.embl.org/>) European Bioinformatics Institute (EBI: <https://www.ebi.ac.uk/>)
- National Center for Biotechnology Information (NCBI: <https://www.ncbi.nlm.nih.gov/>)
- National Institute of Genetics Japan (NIG: <https://www.nig.ac.jp/nig/>)

- **Algunes bases de dades biològiques:**

- DNA-nucleòtids-genòmic: ENA (European Nucleotide Archive: <https://www.ebi.ac.uk/ena/browser/home>), GenBank (NIH genetic sequence database: <https://www.ncbi.nlm.nih.gov/genbank/>), RefSeq (A comprehensive, integrated, non-redundant, well-annotated set of reference sequences including genomic, transcript, and protein: <https://www.ncbi.nlm.nih.gov/refseq/>), DDBJ (DNA Data Bank of Japa: <https://www.ddbj.nig.ac.jp/index-e.html>)
- Proteïnes: UniProtKB (Universal Protein Knowledgebase: <https://www.uniprot.org/>), és la unió de les tres principals bases de dades primàries: Swiss-Prote, TrEMBL i PIR

- **Algunes eines informàtiques que podem utilitzar :**


- Representacions de molècules: Jmol (<https://jmol.sourceforge.net/>)
- Cerca amb bases de dades: Gquery (Global Cross-database NCBI search: <https://www.ncbi.nlm.nih.gov/search/>)
- Cerca de similituds de seqüències: FASTA (<https://en.wikipedia.org/wiki/FASTA>), BLAST ([https://en.wikipedia.org/wiki/BLAST_\(biotechnology\)](https://en.wikipedia.org/wiki/BLAST_(biotechnology)))

Informació adicional

- The European Molecular Biology Laboratory (EMBL) Nucleotide Sequence Database (<http://www.ebi.ac.uk/embl/index.html>) is a comprehensive collection of primary nucleotide sequences maintained at the European Bioinformatics Institute (EBI).
- The DNA Data Bank of Japan (DDBJ) is a biological database that collects DNA sequences. It is located at the National Institute of Genetics (NIG) in the Shizuoka prefecture of Japan.
- UniProt Knowledgebase (UniProtKB) is the central hub for the collection of functional information on proteins, with accurate, consistent and rich annotation. In addition to capturing the core data mandatory for each UniProtKB entry (mainly, the amino acid sequence, protein name or description, taxonomic data and citation information), as much annotation information as possible is added. This includes widely accepted biological ontologies, classifications and cross-references, and clear indications of the quality of annotation in the form of evidence attribution of experimental and computational data.

TEMES A RECORDAR

- La informació és útil si es pot actualitzar, consultar i compartir de forma eficient.
- Les bases de dades habitualment son de tipus relacional.
- El model relacional es basa en taules físiques i enllaços entre taules.
- Cada taula està formada per diferents registres i camps.
- La forma de visualitzar les dades és el que s'anomena una vista.
- Les consultes a les bases de dades es realitzen a través del gestor de bases de dades.
- El llenguatge habitual del gestor de bases de dades es diu SQL.
- Una consulta a la base de dades és un filtre (selecció) de certs camps.
- Els proveïdors de recursos aglutinen moltes bases de dades i moltes eines informàtiques en un entorn semblant.



shutterstock.com · 1255223017

LABORATORI (PRÀCTIQUES)

- Entrez o Gquery ((Global Cross-database NCBI search: <https://www.ncbi.nlm.nih.gov/search/>) és el gestor de bases dades amb que és treballarà en aquesta primera sessió de pràctiques.



- És un sistema disponible al proveïdor NCBI
- Permet accedir a les bases de dades (DBs) més habituals amb una interfície unificada
- El seu ús pot anar des d'una utilització bàsica fins a formes molt sofisticades de consultes

CERCAR INFORMACIÓ SOBRE PRIONS

- La cerca es farà a: <https://www.ncbi.nlm.nih.gov/search/>
- Com a exemple, avui treballarem amb unes proteïnes anomenades **prions**.
- Aquestes proteïnes produeixen, entre altres, la malaltia de Creutzfeldt-Jakob (https://es.wikipedia.org/wiki/Enfermedad_de_Creutzfeldt-Jakob).

Informació adicional

La malaltia de Creutzfeldt-Jakob és una malaltia per prions caracteritzada per un deteriorament progressiu de la funcionalitat mental que evoluciona a demència, sacsejades involuntàries dels músculs i marxa trontollant. Una de les variants es transmet per ingestió de carn contaminada.

CERCAR INFORMACIÓ SOBRE PRIONS

- Si es vol tenir una primera visió de la quantitat d'informació que hi ha sobre els prions, es pot fer una primera cerca general a totes les bases de dades del NCBI:
- Aneu a <https://www.ncbi.nlm.nih.gov/search/>
- Fem una cerca inespecífica (sense filtrar per cap camp concret) del terme 'prions' a totes les bases de dades del NCBI (<https://www.ncbi.nlm.nih.gov/search/all/?term=prions>).
- Veureu que d'entrada ens agrupa la informació per nombre de resultats en cada base de dades. Podríem anar a cada una i explorar els resultats, però com veieu és una cerca massa àmplia que no és molt útil (Results found in 20 databases).

#indiqueu els resultats trobats:

CERCAR INFORMACIÓ SOBRE PRIONS

- En la pantalla anterior, fem clic en la base de dades 'Gene', i fem una cerca del terme 'prion' solament en aquesta base de dades (adoneu-vos de la diferència del nombre de resultats si ho especifiquem en singular respecte d'abans que estava en plural, heu d'anar amb compte amb els termes de cerca!): <https://www.ncbi.nlm.nih.gov/gene/?term=prion>

IMPORTANT Tingueu en compte que les bases de dades es van actualitzant constantment amb noves entrades i entrades actualitzades, i per tant el nombre de resultats pot ser diferent en el vostre cas respecte a les captures de pantalla de les diapos.

#indiqueu els resultats trobats:34

CERCAR INFORMACIÓ SOBRE PRIONS

- La cerca continua sent massa àmplia, ja que com no estem especificant en la nostra consulta en què camps volem buscar el terme 'prion', ens dona resultats que continguin el terme en qualsevol camp (per exemple la paraula 'prion' podria estar en la descripció d'un títol o article relacionat, encara que la seqüència del gen que ens mostra en un resultat no sigui d'un prion).

- A la secció 'Search details', sempre podreu veure la vostra consulta que heu fet 'transcrita' a un format de text. Això us permet guardar la cerca per utilitzar-la en qualsevol altre moment (és especialment útil si la consulta es va complicant, com veurem ara, perquè us estalviarà temps en posteriors cerques)
- Aquesta cerca s'ha fet amb el criteri: prion[All Fields] AND alive[prop]
 - 'alive' vol dir que us està mostrant en els resultats solament registres que es consideren vigents actualment, és a dir amb informació correcta i actualitzada a la darrera versió. Els registres que no es troben en aquesta situació es conserven a la base de dades per qüestions de referència i traçabilitat, però per defecte no se us mostren. Podeu veure en la diapo anterior com a la part de dalt dels resultats.
 - Observeu que abans dels resultats, us apareix el missatge 'See also xxx discontinued or replaced items' . Aquest número que us indica aquí vol dir quants són aquests elements desfasats i els podríeu veure fent click allà (<https://www.ncbi.nlm.nih.gov/gene/?term=prion#see-all>).

- Fem cerques més avançades

#Comentaris