





▼ Introducció a la Bioinformàtica



INTRODUCCIÓ A LA BIOINFORMÀTICA (8h)

- Introducció (dia 1)
- Bases de dades (dia 1)
- Alineament de seqüències (dia1 / dia2)

- Cerques per Similitud (dia 2 / dia 3)
- *Next Generation Sequencing (NGS)* (dia 3 / dia 4)
- Gene Expression Omnibus database (GEO) (dia 4)

Next Generation Sequencing)



Basat en els apunts de l' assignatura Biologia II curs 2022-2023. (Modificació de Toni Monleón-Getino. Departament de Genètica, Microbiologia i Estadística. Grup de recerca BIST3 i GRBIO)
Universitat de Barcelona
Duració:8h


SOLS PER US DOCENT

Introducció a la Seqüenciació i NGS

Què és la Seqüenciació?

La seqüenciació del DNA és el procés de determinar l'ordre precís dels nucleòtids (As, Ts, Cs i Gs) dins d'una molècula de DNA.

- **Objectiu:** "Llegir" el codi genètic.
- **Evolució:** Des del mètode clàssic (Sanger) fins a les tècniques massives actuals.



Què és NGS (Next-Generation Sequencing)?


L'acrònim **NGS** es refereix a **Next-Generation Sequencing** (Seqüenciació de Nova Generació). També es coneix com a **HTS (High-Throughput Sequencing** o Seqüenciació d'Alt Rendiment).

- **Diferència clau:** A diferència de la seqüenciació clàssica (que llegeix un fragment cada vegada), la NGS permet seqüenciar milions de fragments simultàniament (paral·lelisme massiu).
- **Impacte:** Ha revolucionat la biologia permetent seqüenciar genomes complets o transcriptomes en molt poc temps i a baix cost.

Mes informació comercial a: <https://www.lorgen.com/avances-tecnicos-y-cientificos/la-secuenciacion-una-herramienta-clave-para-la-medicina-personalizada/>

Ciències Òmiques

El **Next Generation Sequencing (NGS)** actua com el motor tecnològic indispensable que impulsa les **Ciències Òmiques**, ja que permet generar de manera massiva i ràpida les dades genètiques necessàries per estudiar genomes, transcriptomes i metagenomes complets.



1. Les **Ciències Òmiques** permeten l'estudi massiu i integral de sistemes biològics, analitzant la totalitat de molècules (gens, proteïnes, metabòlits) d'una mostra simultàniament.
2. Les branques principals inclouen la **Genòmica** (estudi de l'ADN), la **Transcriptòmica** (estudi de l'ARN i l'expressió gènica) i la **Proteòmica** (estudi de les proteïnes i la seva funció).
3. També destaquen la **Metabolòmica** (perfils químics) i la **Metagenòmica**, que seqüencia directament l'ADN de comunitats microbianes complexes (com la microbiota intestinal) sense haver de cultivar els organismes.

1. Tècniques de Seqüenciació: Visió General

Hi ha diferents tecnologies disponibles, cadascuna amb característiques específiques de longitud de lectura (**Read Length**) i fiabilitat.

Resum de Tecnologies

Tecnologia	Longitud màxima (bp)	Fiabilitat (%)	Notes
Ion semiconductor	~600 bp	99.6%	Detecta protons (H+) alliberats.
Pyrosequencing	~700 bp	99.9%	Detecta llum (pirofosfat).
Synthesis (Illumina)	~500 bp	99.9%	Més utilitzada (SBS).
Nanopore	~500,000 bp	92-97%	Lectures molt llargues, però més error.
SMRT (PacBio)	~100,000 bp	87%	Single-molecule real-time.
<i>Sanger (Clàssic)</i>	~900 bp	99.9%	<i>Gold standard</i> per a validacions petites.

Nota: bp = Base Pairs (parells de bases). Indica la longitud del fragment llegit.


Illumina: Sequencing by Synthesis (SBS)

És la tècnica dominant actualment. Es basa en la síntesi de la cadena complementària utilitzant nucleòtids marcats amb fluorescència.


<https://microbenotes.com/wp-content/uploads/2024/11/Illumina-Sequencing-Steps.jpeg>

Illumina Sequencing Steps


① Library preparation




② DNA library bridge amplification



③ DNA library sequencing



④ Alignment and data analysis



2. Resultats High-Throughput (HTS)


La NGS ofereix avantatges dràstics respecte als mètodes antics :

1. **Escalabilitat:** Es pot seqüenciar un genoma o transcriptoma en un sol experiment.
2. **Cost:** Reducció tremenda (1 milió de bp costa entre 1 i 0.1).
3. **Temps:** En 2h es poden seqüenciar 80 milions de bases.
4. **Sense clonatge:** No calen etapes prèvies de clonatge o PCR complexes (tot i que sovint hi ha una amplificació per PCR durant la preparació de la llibreria).

Conceptes Clau: Els "Reads"

https://en.wikipedia.org/wiki/Linked-read_sequencing

- **Read (Lectura):** Fragment de DNA que prové d'una única seqüenciació.
- **Single Ends (SE):** Es llegeix la molècula només des d'un extrem. Més econòmic, suficient per a quantificar expressió.
- **Paired Ends (PE):** Es seqüencia la mateixa molècula pels dos extrems.
 - Permet saber la distància entre lectures.
 - Millora el mapatge en regions repetitives i la reconstrucció del genoma (*assembly*).
 - Si se solapen, assegurem la lectura completa del fragment.



3. Transcriptòmica: RNA-seq

L'**RNA-seq** és l'aplicació de la NGS per estudiar l'RNA (transcriptoma).


Comparativa: Clàssic vs. RNA-seq

A. Tècnica Clàssica (Microarrays / Aïllament estàndard)

- Recupera principalment **mRNAs** (missatgers) utilitzant les cues poli-A.
- Només veus allò conegut (sondes predefinides).
- Representa aprox. el **2%** de l'RNA total.

B. RNA-seq

- Recupera **TOTS els RNAs** (incloent miRNAs, ncRNAs - non coding).
- **Repte:** Cal eliminar els rRNAs (ribosòmics), que són el 90% del total.
- **Avantatge:** Permet descobrir nous tipus d'RNA (aprox 8% del total) que no són ni missatgers ni ribosòmics.
- L'amplificació es fa en posicions aleatòries.



4. Profunditat de Seqüenciació (Sequencing Depth)

Definició: És la quantitat de *reads* (lectures) obtingudes per mostra.

A major profunditat, més sensibilitat tenim per detectar gens poc expressats.

- **5M reads (5 Milions):**
 - Detectar tots els gens d'un genoma.
 - Quantificar gens d'expressió mitjana o alta.
- **100M reads:**
 - Quantificació precisa de **tots** els gens (inclosos els de baixa expressió).
 - Implica un esforç computacional molt major.

5. Controls de Qualitat (QC)

Abans d'analitzar, cal "netejar" les dades. Errors poc freqüents (1/10000) poden ser problemàtics quan tenim milions de lectures.

1. **Biaix de PCR (G+C bias):** La PCR pot amplificar més certes regions segons el seu contingut en Guanina i Citosina. Cal normalitzar.
2. **Adaptadors:** Cal eliminar informàticament les seqüències tècniques (primers) afegides als extrems dels *reads*.
3. **Sobrerrepresentació (k-mers):** Eliminar seqüències artificials o contaminants molt freqüents.
4. **Rèpliques Tècniques:** S'espera una correlació molt alta entre rèpliques ($r^2 > 0.9$).

Desenvolupament dels conceptes de Control de Qualitat (QC)

L'objectiu del QC és distingir entre **biologia real** (mutacions, expressions gèniques) i **soroll tècnic** (errors de la màquina). A continuació, expliquem què vol dir cada punt.

5.1. Biaix de PCR (G+C Bias)

El Concepte: La PCR és el procés de "fotocopiar" l'ADN per tenir-ne prou quantitat per analitzar. L'ADN està format per lletres (A, T, C, G).

- Les unions entre **G i C** són molt fortes (3 enllaços químics).
- Les unions entre **A i T** són més febles (2 enllaços).

El Problema: Imagina que la "fotocopiadora" (l'enzim) s'encalla quan intenta copiar parts de l'ADN que estan molt "enganxades" (riques en GC). Això fa que tinguem menys lectures d'aquestes zones del que tocaria.

Solució (Normalització): Apliquem una correcció matemàtica. Si sabem que la màquina llegeix malament les zones GC, l'ordinador "infla" artificialment aquests valors per recuperar la realitat biològica.

5.2. Adaptadors (Adapters)

El Concepte: Perquè el seqüenciador pugui "agafar" els fragments d'ADN, hem d'enganxar-li unes cues artificials als extrems. Aquests "mànecs" són els adaptadors.

El Problema: Si el fragment d'ADN és curt, la màquina llegeix l'ADN i continua llegint l'adaptador. L'adaptador no és part del genoma, és com l'etiqueta del preu en una samarreta.

Codi d'exemple (Visualització): Necessitem fer **Trimming** (retallada) per eliminar la part tècnica.

```
LECTURA_BRUTA: Gen_Interessant_ATGC + ADAPTADOR_ARTIFICIAL
RESULTAT_NET:   Gen_Interessant_ATGC
```

5.3. Sobrerrepresentació (K-mers)

El Concepte: Un k-mer és una seqüència curta de lletres (ex: "ATGC" és un 4-mer). La biologia és diversa i complexa, per tant, esperem varietat. El Problema: Si trobem que una seqüència exacta es repeteix milions de vegades, és sospitós.

Analogia: Si obres un llibre i la frase "el gat és blau" surt 500 vegades seguides, no és una novel·la normal; és un error d'impremta o algú ha escrit a sobre. Causes: Sol indicar contaminació (bacteris externs) o errors de la PCR.

5.4. Rèpliques Tècniques (Estadística)

El Concepte: Per demostrar que l'experiment és vàlid, analitzem la mateixa mostra dues vegades per separat (Rèplica A i Rèplica B). L'Explicació: Si la màquina funciona bé, els resultats han de ser idèntics. Si et peses dues vegades seguides en una bàscula, el pes ha de ser el mateix.

Mètrica (r^2): Utilitzem el coeficient de determinació (r^2) per mesurar la semblança.

1.0 = Idèntic

0.0 = Totalment diferent.

En seqüenciació exigim una qualitat molt alta:


$$r^2 > 0.9$$

Si el valor és inferior, les dades no són reproduïbles i s'han de descartar.

6. Referència pel Mapatge (Mapping)

El **Mapatge** consisteix a buscar el lloc d'origen de cada *read* dins del genoma/transcriptoma.

<https://training.galaxyproject.org/training-material/topics/sequence-analysis/tutorials/mapping/tutorial.html>



Estratègies segons la informació disponible:

1. Genòmica (Reference Genome):

- Usem un genoma ja seqüenciat (Ex: Humà, Ratolí).
- Màxima qualitat.

2. Transcriptòmica (Reference Transcriptome):

- Mapem contra el conjunt de transcrits coneguts.
- Problema: Dificultat per quantificar gens amb isoformes similars (repeticions).

3. De Novo Assembly (Ensamblatge de nou):

- Per a organismes nous o poc estudiats.
- Es reconstrueix el transcriptoma ajuntant els *reads* que se solapen (com un puzle sense caixa).

7. Expressió Diferencial (DE)

L'objectiu sol ser comparar dues condicions (Ex: Tumor vs. Teixit sa) per veure quins gens canvien.

Log Odds-Ratio

Per mesurar el canvi (Fold Change), sovint s'utilitza el logaritme en base 2:

$$\text{Log}_2 \left(\frac{\text{Expressió Condició 1}}{\text{Expressió Condició 2}} \right)$$

Necessitat de Normalitzar

No podem comparar directament els *conteo* de reads (raw counts) perquè:

1. **Llargada del gen:** Com més llarg és un transcrit, més *reads* tindrà per atzar.
2. **Profunditat total:** Si l'experiment A té el doble de reads totals que l'experiment B, tots els gens semblaran el doble d'expressats.

8. Normalitzacions: RPKM

Per corregir els biaixos anteriors, utilitzem unitats normalitzades com **RPKM** (Reads Per Kilobase Million).

Fórmula del RPKM

Es calcula en dos passos o directament:

1. **RS (Reads per Sample):** Normalitzar per la profunditat total (en milions).
2. **RPM (Reads Per Million):** Dividir els reads del gen per RS.
3. **RPKM:** Dividir RPM per la longitud del gen (en kilobases).

La fórmula combinada és:

$$RPKM = \frac{10^9 \cdot \text{reads_transcrit}}{\text{reads_totals} \cdot \text{long_transcrit}}$$

Avís: La normalització pot emascarar canvis globals. Si **tot** el transcriptoma augmenta (ex: cèl·lula creixent), la normalització relativa no ho mostrarà.

9. Workflows (Fluxos de treball)

No hi ha una única manera de processar les dades. Depèn de si tenim referència o no .

- **(a) Amb Genoma de Referència:**
 - *Reads* → Mapatge amb **Gapped mapper** (Ex: TopHat, STAR) → Identificació de transcrits (Cufflinks).
- **(b) Amb Transcriptoma de Referència:**
 - *Reads* → Mapatge amb **Ungapped mapper** (Ex: Bowtie) → Quantificació (RSEM, Kallisto).
- **(c) Sense Referència (De novo):**
 - *Reads* → Ensamblatge amb grafs de Bruijn (Ex: Trinity) → Generar transcrits → Mapejar els reads de nou contra el que hem creat.



Actualització 2025: Què ha canviat?

La bioinformàtica avança molt ràpid. Aquests són els conceptes del material original que han evolucionat:

1. Adéu al RPKM, Hola al TPM

L'unitat **RPKM** explicada anteriorment té un problema matemàtic: la suma total varia entre mostres, fent difícil la comparació.

- **Estàndard Actual: TPM (Transcripts Per Million).**
- **Avantatge:** La suma dels TPMs de tots els gens en una mostra sempre és 1, 000, 000. Si un gen té 50 TPM en la mostra A i 100 TPM en la mostra B, podem dir que la seva proporció relativa s'ha doblat.

2. Evolució del Software (Tools)

Moltes eines esmentades al flux de treball clàssic (TopHat, Cufflinks) han estat substituïdes per versions més ràpides:

Pas	Eina "Clàssica"	Estàndard Modern (2024+)	Per què?
Alineador	TopHat	STAR / HISAT2	TopHat està discontinuat. STAR és molt més pre
Ensamblatge	Cufflinks	StringTie	StringTie és més ràpid i reconstrueix millor isofo
Quantificació	HTSeq	Salmon / Kallisto	Usen <i>pseudo-alineament</i> . Poden quantificar una

3. La Revolució de les "Long Reads"

Al material original, es deia que **Nanopore** i **PacBio** tenien molt error. Això ja no és cert:

- **PacBio HiFi:** Ara ofereix lectures de >15,000 bp amb **99.9% de precisió**.
- **Nanopore:** Ha millorat dràsticament (>99%) i permet seqüenciar DNA/RNA natiu (sense PCR), detectant metilació directament.

Resum Final

- **NGS:** Tècniques massives, més ràpides i barates.
- **RNA-seq:** Permet analitzar tot l'RNA, no només el conegut.
- **Profunditat:** Clau per a la sensibilitat de l'experiment.
- **QC:** Imprescindible netejar dades (adaptadors, qualitat).
- **Anàlisi:**
 - Mapatge (contra genoma o *de novo*).

- Quantificació (Normalitzar amb RPKM).