





✓ Introducció a la Bioinformàtica



🌐 INTRODUCCIÓ A LA BIOINFORMÀTICA (8h)

- Introducció (dia 1)
- Bases de dades (dia 1)
- Alineament de seqüències (dia1 / dia2)

- Cerques per Similitud (dia 2 / dia 2)
- Next Generation Sequencing (NGS) (dia 3 / dia 4)
- **Gene Expression Omnibus database (GEO) (dia 4)**

Gene Expression Omnibus database (GEO)



Basat en els apunts de l' assignatura Biologia II curs 2022-2023. (Modificació de Toni Monleón-Getino. Departament de Genètica, Microbiologia i Estadística. Grup de recerca BIST3 i GRBIO)
Universitat de Barcelona
Duració:8h

SOLS PER US DOCENT

 Gene Expression Omnibus database (GEO).



El Gene Expression Omnibus (GEO): El teu magatzem de dades genòmiques

Què és el GEO?

El **Gene Expression Omnibus (GEO)** és una vasta base de dades pública on s'emmagatzemen i comparteixen dades d'alta qualitat sobre experiments d'expressió gènica i genòmica. Imagina't una biblioteca gegant on pots trobar informació sobre els gens de qualsevol organisme, des d'humans fins a bacteris.

Per què és important?

- **Accés obert:** Qualsevol investigador, estudiant o persona interessada pot accedir a aquestes dades de forma gratuïta.
- **Col·laboració global:** Facilita la col·laboració entre científics de tot el món, accelerant el descobriment científic.
- **Reproductibilitat:** Permet que altres investigadors repliquin experiments i verifiquin resultats.
- **Desenvolupament de noves eines i mètodes:** Serveix de base per al desenvolupament de noves eines bioinformàtiques i mètodes d'anàlisi.

Quin tipus de dades trobem al GEO?

- **Expressió gènica:** Com s'activen o desactiven els gens en diferents condicions (malalties, tractaments, etc.).
- **Microarrays:** Dades de microarrays, una tecnologia per mesurar l'expressió de milers de gens alhora.
- **RNA-seq:** Dades de seqüenciació d'RNA, que proporcionen informació detallada sobre l'expressió gènica.
- **Genotipatge:** Informació sobre les variacions genètiques entre individus.

- **Metadades:** Informació detallada sobre els experiments, com les mostres utilitzades, els tractaments aplicats i les plataformes tecnològiques.

Com està organitzat el GEO?

El GEO està organitzat en sèries, que agrupen experiments relacionats. Cada sèrie conté un o més conjunts de dades, que al seu torn contenen les mostres individuals.

Com buscar al GEO?

Pots realitzar cerques per paraules clau, organismes, plataformes tecnològiques o qualsevol altra característica de les dades. El GEO proporciona una interfície de cerca intuïtiva i eines d'anàlisi.

LINK A: <https://www.ncbi.nlm.nih.gov/geo/>



Entreu a la pàgina web de GEO: <https://www.ncbi.nlm.nih.gov/geo/>

NOTES ADICIONALS:

Inicialment contenia dades de microarrays, però actualment la major part de dades noves provenen de dades de RNA-seq

- La base de dades GEO (Gene Expression Omnibus) de NCBI, a més de les entrades principals, també inclou dades d'expressió de genes, dades de microarrays i dades de RNA-seq.
- Els formats en els que es poden estar les dades són molt variats (fitxers d'expressió, fitxers de metadades, etc.).
- Aquests representen una agrupació d'experiments relacionats entre si.

Què són els conjunts de dades?

Imagina que diversos investigadors estudien diferents aspectes d'una mateixa malaltia, com per exemple, el **càncer de mama**. Cadascun d'aquests investigadors realitzarà els seus propis experiments, generant dades d'expressió gènica. En lloc de tenir aquests experiments dispersos, GEO permet agrupar-los en un *conjunt de dades*.

Aquest conjunt de dades contindrà informació sobre:

- **Els experiments individuals:** Les dades d'expressió gènica generades per cada investigador.
- **La relació entre els experiments:** Per exemple, que tots estudien el càncer de mama, o un subtipus específic.
- **Informació addicional:** Com ara dades clíniques dels pacients, disseny experimental, etc.

Exemples:

- Un conjunt de dades podria agrupar estudis que investiguen la resposta al tractament en diferents subtipus de càncer de pulmó.
- Un altre conjunt de dades podria contenir experiments que analitzen l'efecte d'un nou fàrmac en cèl·lules canceroses.

En resum:

Els conjunts de dades a GEO són com "carpetes" que organitzen experiments relacionats, facilitant la consulta i l'anàlisi conjunta de les dades per a la comunitat científica. Això permet obtenir una visió més completa i integrada de les dades, i facilita la recerca i la metaanàlisi.

Plataformes a Gene Expression Omnibus database (GEO).

- L'identificador únic (ID) de cada plataforma es compon de les lletres GPL+número (GPLxxx)
- Contenen una descripció rigorosa de la plataforma utilitzada:
 - Microarrays => sondes utilitzades per cada posició
 - RNA-seq => Tipus de sondes, tècnica, ...
- Poden contenir explicacions d'altres processos previs necessaris per utilitzar aquesta plataforma (amplificacions, filtrats, ...)

Mireu GEO: <https://www.ncbi.nlm.nih.gov/geo/browse/?view=platforms>

CONCRETAMENT UN DELS REGISTRES:

<https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GPL34065>

Mostres (Samples) a Gene Expression Omnibus database (GEO).

- L'identificador únic (ID) de cada mostra es compon de les lletres GSM+número (GSMxxx)
- Cal especificar les condicions en que es va obtenir aquella mostra concreta:
 - Hibridació
 - Obtenció
 - Amplificació
 - Altres dades (importantes per analitzar aquella mostra)
- Cal posar en context la mostra respecte a l'experiment global

Mireu GEO: <https://www.ncbi.nlm.nih.gov/geo/browse/?view=samples>

CONCRETAMENT UN DELS REGISTRES:

<https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSM5011610>

 Series a Gene Expression Omnibus database (GEO).

- L'identificador únic (ID) de cada sèrie es compon de les lletres GSE+número (GSExxx):
- Equivalen al que entenem per un experiment.
- Definir totes les mostres que engloba aquella sèrie.
- Descriure els objectius de l'estudi global i del conjunt de mostres.
- Habitualment també contenen conclusions o anàlisis que s'hagin realitzat.

Mireu GEO: <https://www.ncbi.nlm.nih.gov/geo/browse/?view=series>

CONCRETAMENT UN DELS REGISTRES:

<https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE164469>



shutterstock.com · 1255223017

LABORATORI (PRÀCTIQUES)

Obtenir dades de GEO

1. Accediu al servidor de GEO i descarregueu les dades de la sèrie GSE119794 (link <https://www.ncbi.nlm.nih.gov/geo/browse/?view=series> i <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE119794>, una de les mostres: <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSM3383891> DESCARREGUEU)
2. Quants samples te aquest experiment? de quin tipus son? Quina plataforma han fet servir per obtenir-les? Visualitza un sample
3. Seleccioneu les dades de mRNAs pels individus controls: 1, 2, 4, 6 i 10 i tumors: 3, 4, 8, 9 i 10) i ajunteu-les en un únic fitxer, on les files siguin els gens i les columnes els diferents samples. Quantes files i columnes tindrà aquest fitxer?
4. Si no has pogut fer la tasca anterior, descarrega't el fitxer del campus anomenat GSE119794.tsv, que és el que utilitzarem pels anàlisis posteriors (Obrir amb EXCEL, EN FORMAT TAULA. UTILITZEU OBRIR FITXER. o alternativament en RSTUDIO-->IMPORT DATASET):

El fitxer te una capçalera com:

- VARIABLE CLASS CATEGORICAL{tumor,control}
VALUES{control,control,control,control,control,tumor,tumor,tumor,tumor,tumor}
DESCRIPTION{}
- NAMES control-01 control-02 control-04 control-06 control-10 tumor-03
tumor-04 tumor-08 tumor-09 tumor-10

Deixeu sols la línia de NAMES

O be:

","control_1","control_2","control_3","control_4","control_5","tumor_1","tumor_2","tumor_3","tumor_4","tumor_5" (SI UTILITZES AQUESTA SEGONA FORMA, JA ESTÀ BÉ I NO S' HA DE FER RES)

#Respostes i comentaris

Expressió diferencial

L'anàlisi d'expressió diferencial és una tècnica essencial en bioinformàtica que ens permet identificar gens que es comporten de manera diferent entre diferents condicions experimentals (per exemple, cèl·lules sanes vs. cèl·lules canceroses).

Aquest tutorial proporciona una introducció bàsica a aquest concepte i a les eines que s'utilitzen per dur-lo a terme.

- Què és l'Anàlisi d'Expressió Diferencial?
- Objectiu: Identificar gens que s'expressen de manera diferent entre dos o més grups de mostres.
- Dades: S'utilitzen dades d'RNA-seq, que quantifiquen la quantitat d'ARN missatger (ARNm) present en una mostra. Procés:
- Normalització: Les dades d'RNA-seq es normalitzen per eliminar biaixos tècnics i fer les mostres comparables.
- Comparació: Es compara l'expressió de cada gen entre els diferents grups:
 - Test estadístic: S'aplica un test estadístic per determinar si les diferències observades són estadísticament significatives.
 - Ajust de valor p: S'ajusta el valor p per corregir la taxa de descobriment falsa (FDR).

PRÀCTICA

Per aquesta part s'utilitzara un programari que permeti l'anàlisi d'expressió diferencial a partir del fitxer que heu obtingut abans:


PREGUNTES:

1. Quantes files i columnes té el fitxer GSE119794.tsv? Què són les dades que hi trobem?

#Comentaris i resultats

US D' UNA EINA DE TIPUS WORKFLOW O PIPELINE

Utilitzarem IDEP és una aplicació web integrada per a l'anàlisi d'expressió diferencial i de vies de dades d'RNA-seq.



2. Connecteu-vos al servidor IDEP (<http://bioinformatics.sdstate.edu/idep/>) (ALTERNATIU A BABELOMICS, que en ocasions deixa de funcionar) i carregueu (Pestanya: Load data) les dades del fitxer GSE119794_1.csv com matriu de dades d'expressió (reads counts data)
3. Per comparar l'expressió diferencial (DE) entre aquests 2 grups de RNA-seq, primer cal normalitzar les dades? Com? **ANEU A LA PESTANYA PRE-PROCESS I OBSERVEU LES DIFERENTES OPCIONS DE PREPROCESSAT I LES QUE APAREIXEN PER DEFECTE (son les que utilitzarem).**

#COMENTARIS I RESULTATS

4. Compareu tumors i controls (class comparison) i obteniu una llista de DE gens (com a paràmetres, no normalitzeu, corregiu la multiplicitat per FDR i talleu la llista en un adj. pvalue 0.003). **ANEU A LA PESTANYA DEG1 (un dels mètodes habituals en el càlcul d'expressió diferencial) i canvieu el valor de FDR cutoff a 0.003. Indiqueu també que el "Experimental design" és "control vs. tumor" i feu SUBMIT". Els resultats es poden veure a "Results" i a Numbers of differentially expressed genes for all comparisons. "B-A" means B vs. A. Interaction terms start with "I:"**

Quants gens obtenim? Que vol dir Up i Down?

CARACTERITZACIÓ FUNCIONAL DE GENS



Podem fer una caracterització funcional dels gens diferencialment expressats obtinguts amb IDEP **Veure apartat PATHWAY (GSEA, FER SUBMIT i mirar els**

diagrames que apareixen especialment KEGG i GO), pero anem a utilitzar una altra eina específica per fer aquesta tasca.

Caracterització funcional amb DAVID

Què és DAVID? The Database for Annotation, Visualization and Integrated Discovery (DAVID) provides a comprehensive set of functional annotation tools for investigators to understand the biological meaning behind large lists of genes.

1. De la llista de gens triats, deixa només el nom. Si no pots fer-ho, utilitza el fitxer "de_gene_list.txt"
2. Anem al servidor DAVID (<https://david.ncifcrf.gov/> i <https://david.ncifcrf.gov/content.jsp?file=release.html>, START ANALYSIS in: <https://david.ncifcrf.gov/tools.jsp>) per fer l'anotació funcional de la llista de gens, fent servir enriquiment funcional
3. Carreguem (upload) la nostra llista de gens (com a identificadors triem: OFFICIAL_GENE_SYMBOL. Com a organisme triem "Homo sapiens"), finalment indiquem que "Step 3: List Type Gene List" i ho executem ("SUBMIT LIST")
4. Què és la taula d'anotacions funcionals? (Veure el help a: https://david.ncifcrf.gov/content.jsp?file=functional_annotation.html#summary)

#Respostes i comentaris

5. Què és la taula de funcions enriquides? (Veure el help a: https://david.ncifcrf.gov/content.jsp?file=functional_annotation.html#summary)

#Respostes i comentaris

6. Què és l'agrupament per funcions enriquides? (Veure el help a: https://david.ncifcrf.gov/content.jsp?file=functional_annotation.html#summary)

#Respostes i comentaris

ALGUNS COMENTARIS SOBRE DAVID

- La taula d'anotacions funcionals en DAVID és una eina essencial per entendre el significat biològic d'un conjunt de gens. Aquesta taula proporciona una visió general de les funcions, processos biològics i components cel·lulars que estan sobre-representats en la teva llista de gens d'interès.
- Què conté aquesta taula?

- Funcions biològiques: Descriu el que fa un gen o un producte gènic (per exemple, catabolisme, transport).
- Processos biològics: Representa un conjunt ordenat d'activitats moleculars que es produeixen en una cèl·lula per aconseguir un objectiu específic (per exemple, cicle cel·lular, senyalització).
- Components cel·lulars: Indica la localització subcel·lular on es troba un gen o un producte gènic (per exemple, nucli, membrana).
- Com s'interpreta?
 - Enriquiment: Si un terme (funció, procés o component) apareix amb més freqüència en la teva llista de gens que en una llista de fons aleatòria, es considera enriquit. Això suggereix que els gens de la teva llista estan involucrats en aquest terme de manera significativa.
 - Valor p: El valor p indica la probabilitat d'observar un enriquiment tan gran o més gran per atzar. Un valor p baix indica un enriquiment més significatiu.
 - Correcció de la taxa de descobriment falsa (FDR): S'utilitza per controlar el nombre de falsos positius, és a dir, termes que semblen enriquits però en realitat no ho són.
- Què és l'agrupament per funcions enriquides?
 - L'agrupament per funcions enriquides és una forma de visualitzar i interpretar millor els resultats de l'anàlisi d'enriquiment. En lloc de veure una llarga llista de termes enriquits, els termes similars es agrupen per crear categories més grans i significatives. Això facilita la identificació de les principals funcions i processos biològics que caracteritzen la teva llista de gens.
- Per què és important la taula d'anotacions funcionals?
 - Generació d'hipòtesis: Permet generar hipòtesis sobre els possibles mecanismes moleculars que subjauen un fenotip o una condició biològica determinada.
 - Validació de resultats: Ajuda a validar els resultats d'altres tipus d'anàlisi, com ara l'anàlisi de xarxes de gens.
 - Identificació de nous biomarcadors: Pot identificar nous gens o proteïnes